Разбор летучки

Лекция 6

Линейные методы классификации

Екатерина Тузова

Мотивирующий пример

Пример

Пример

Пример

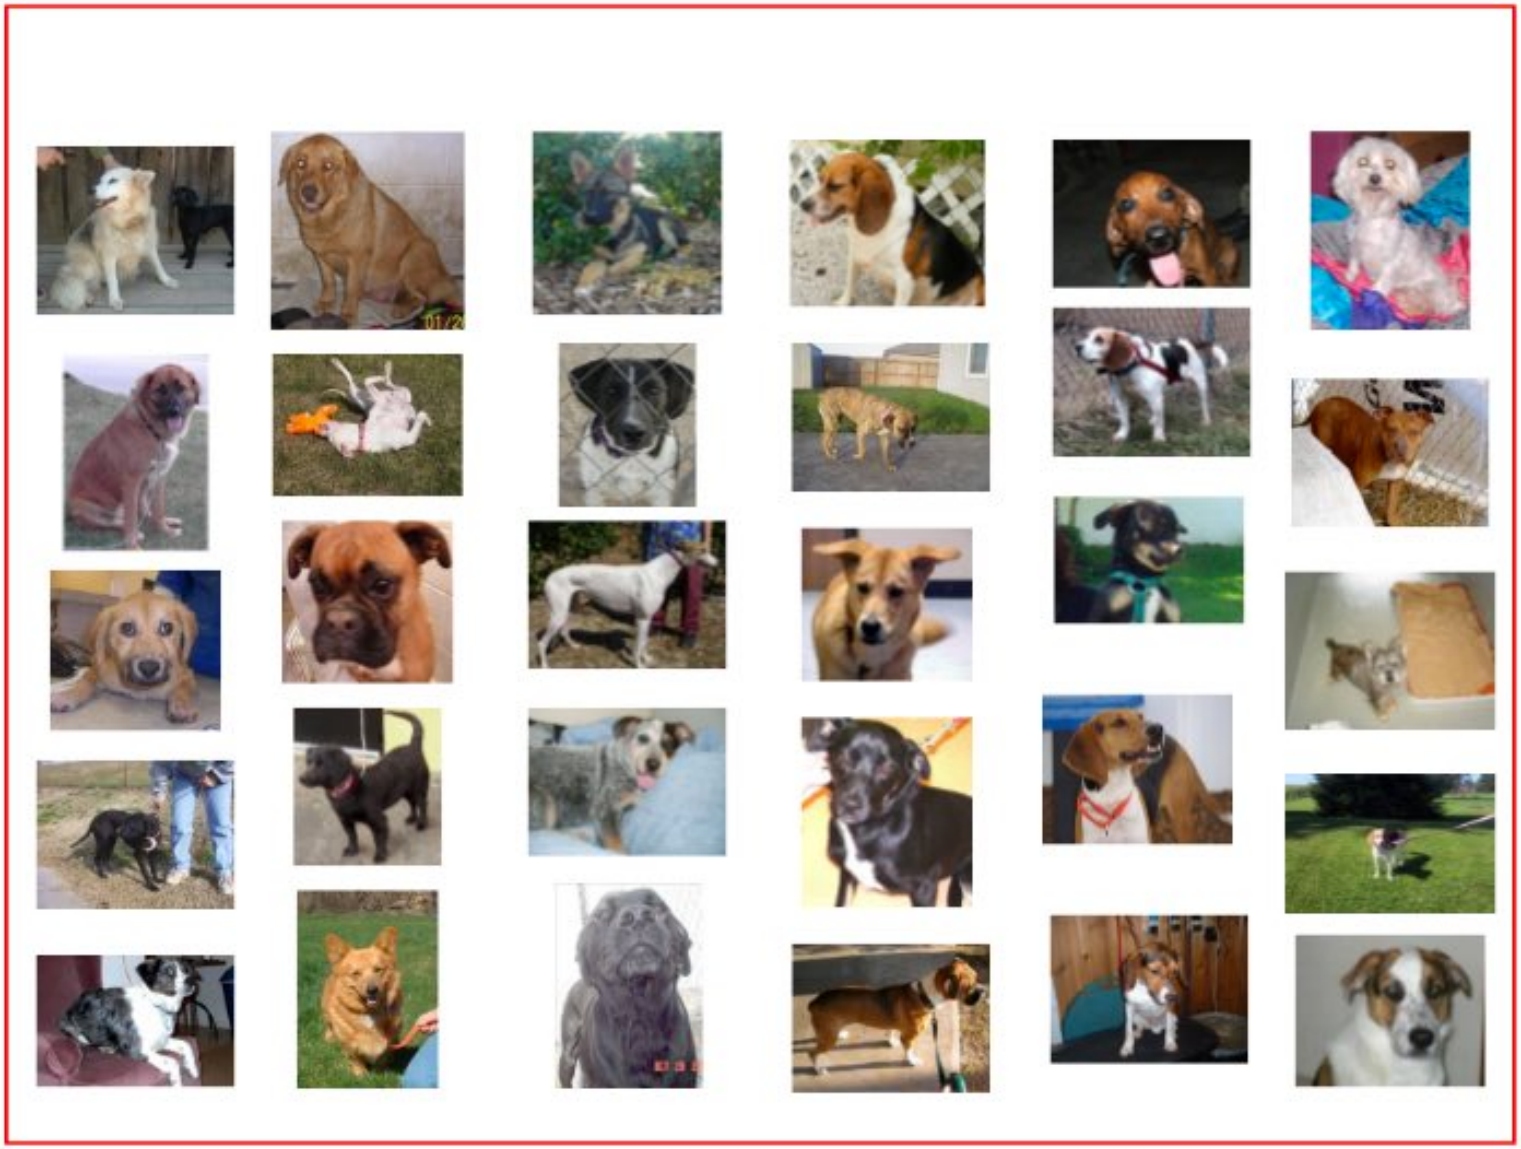

Постановка задачи

$X = \mathbb{R}^n$, $Y = \{-1, +1\}$
$X^l = (x_i, y_i)_{i=1}^l$ – обучающая выборка

Задача: Построить алгоритм $a\colon X \to Y$, способный классифицировать произвольный объект $x \in X$.

Перцептрон

Идея: $(n-1)$-мерную гиперплоскость, которая разделяет данные.

Пример

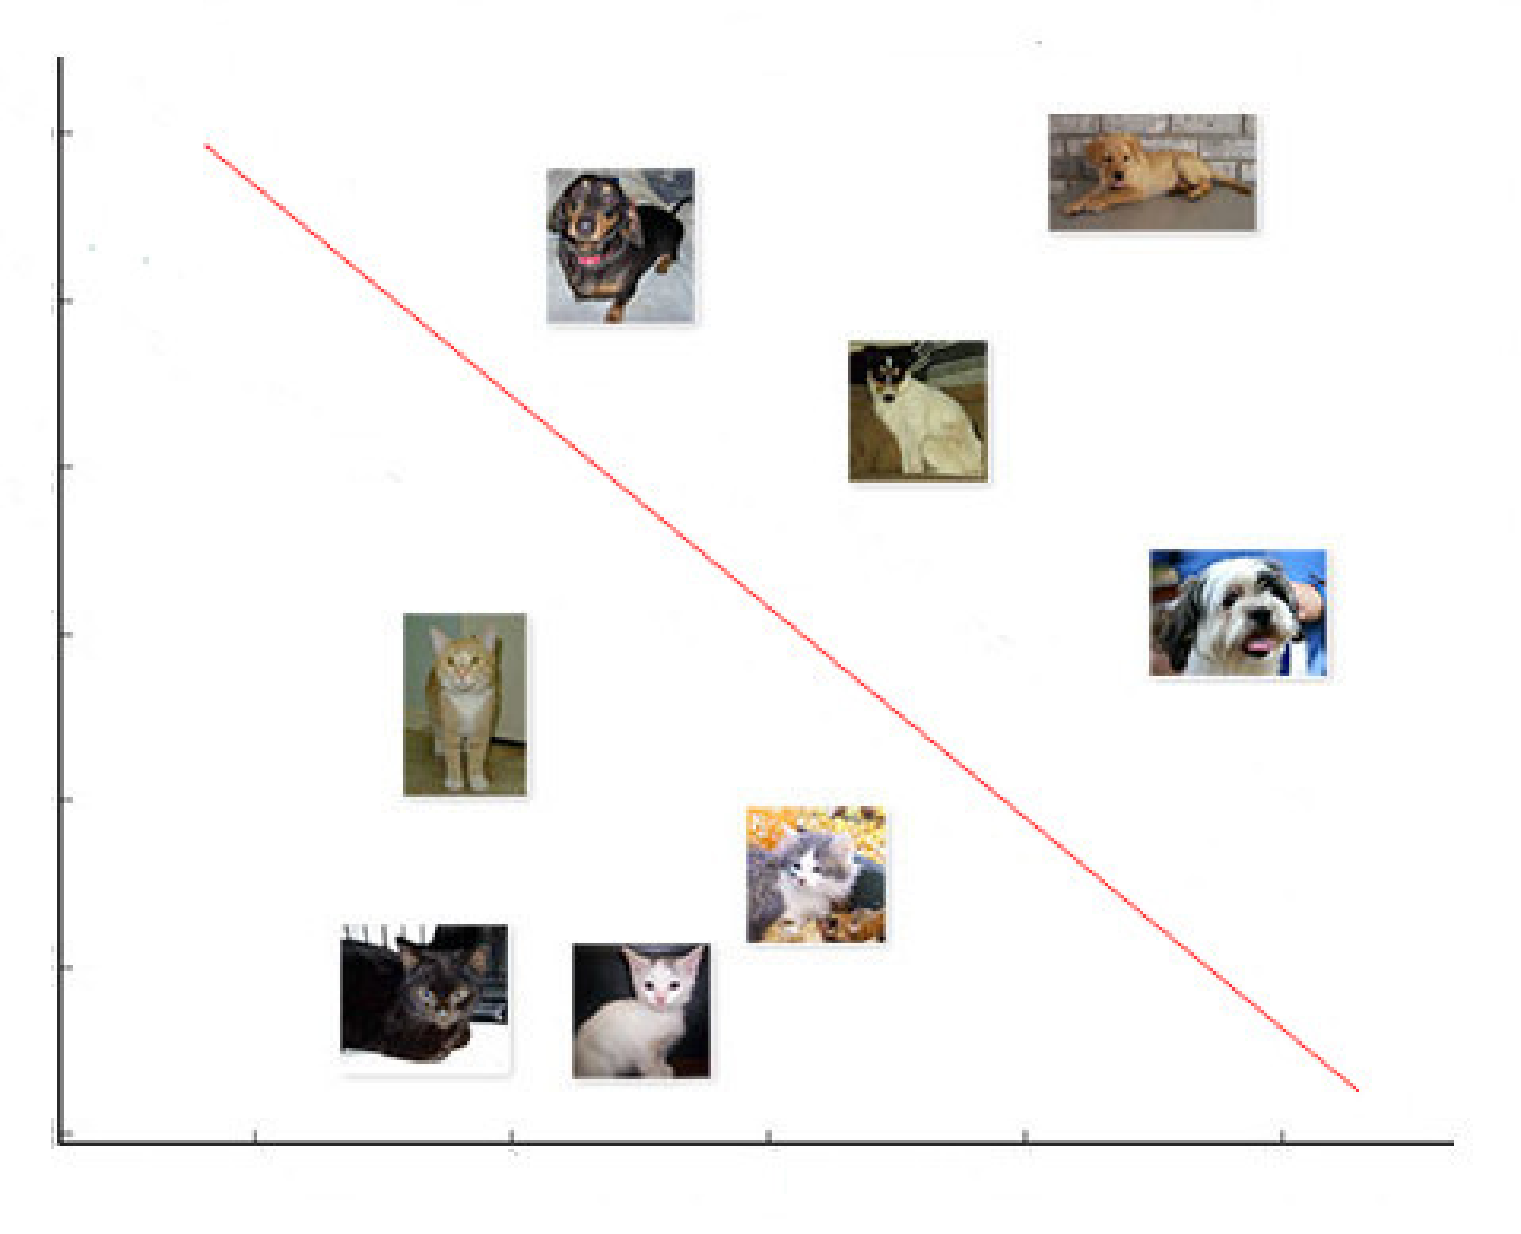

Модель McCulloch-Pitts

$X = \mathbb{R}^n$, $Y = \{-1, +1\}$

Модель McCulloch-Pitts

$X = \mathbb{R}^n$, $Y = \{-1, +1\}$

$$a(x, w) = \sigma(\sum_{j=1}^{n} w_j x^j - w_0) = \sigma(\langle \mathbf{w}, \mathbf{x} \rangle)$$

x^j — признаки объекта, $j = 1, \ldots, n$

$w_j \in R$ – веса признаков

$\sigma(s)$ – функция активации (например, sign)

Модель McCulloch-Pitts

$X = \mathbb{R}^n$, $Y = \{-1, +1\}$

$$a(x, w) = \sigma(\sum_{j=1}^{n} w_j x^j - w_0) = \sigma(\langle \mathbf{w}, \mathbf{x} \rangle)$$

x^j — признаки объекта, $j = 1, \ldots, n$

$w_j \in R$ – веса признаков

$\sigma(s)$ – функция активации (например, sign)

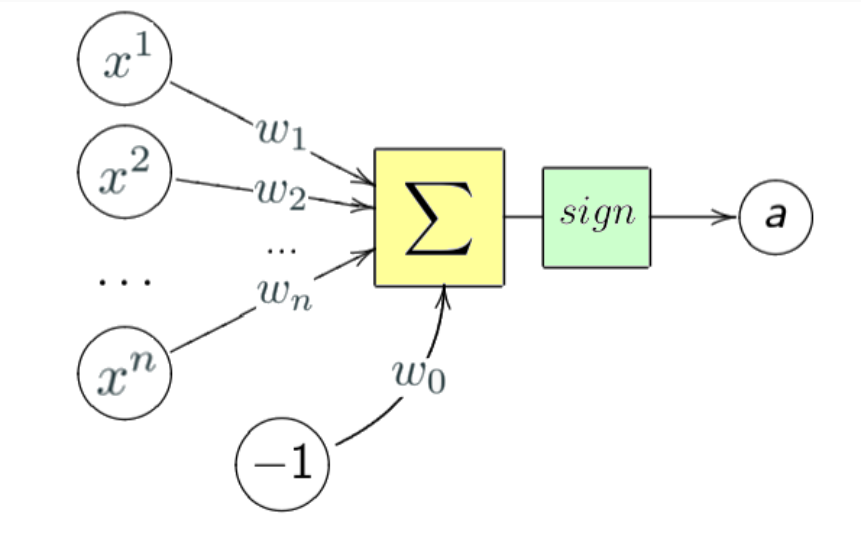

Как подобрать веса w?

Идея

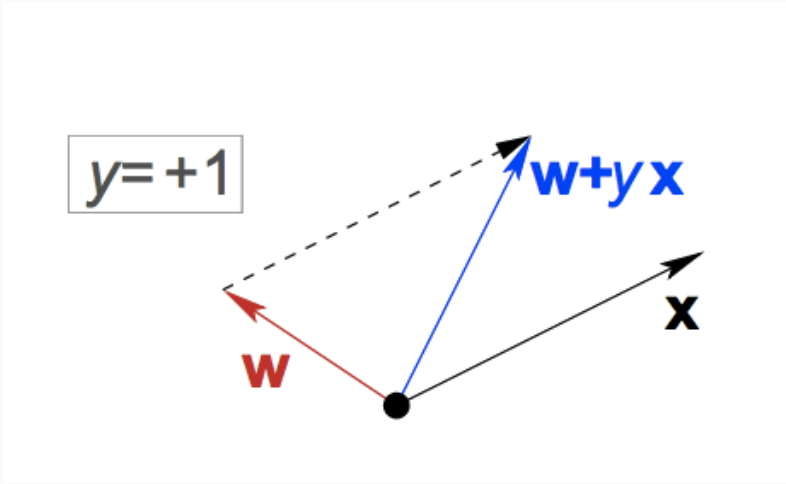

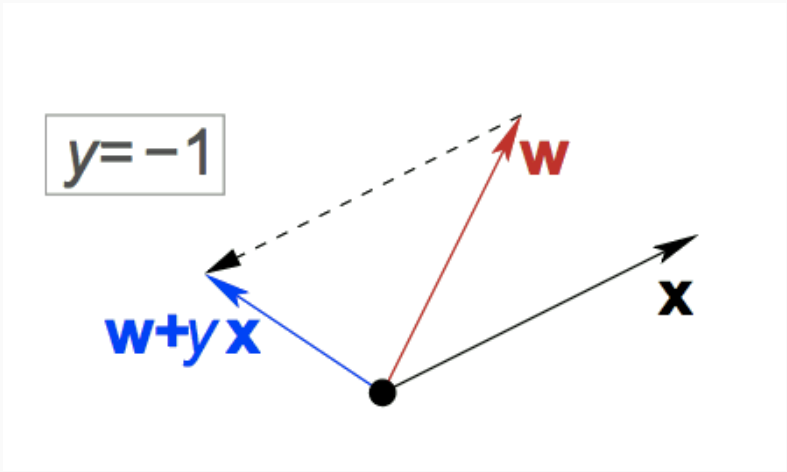

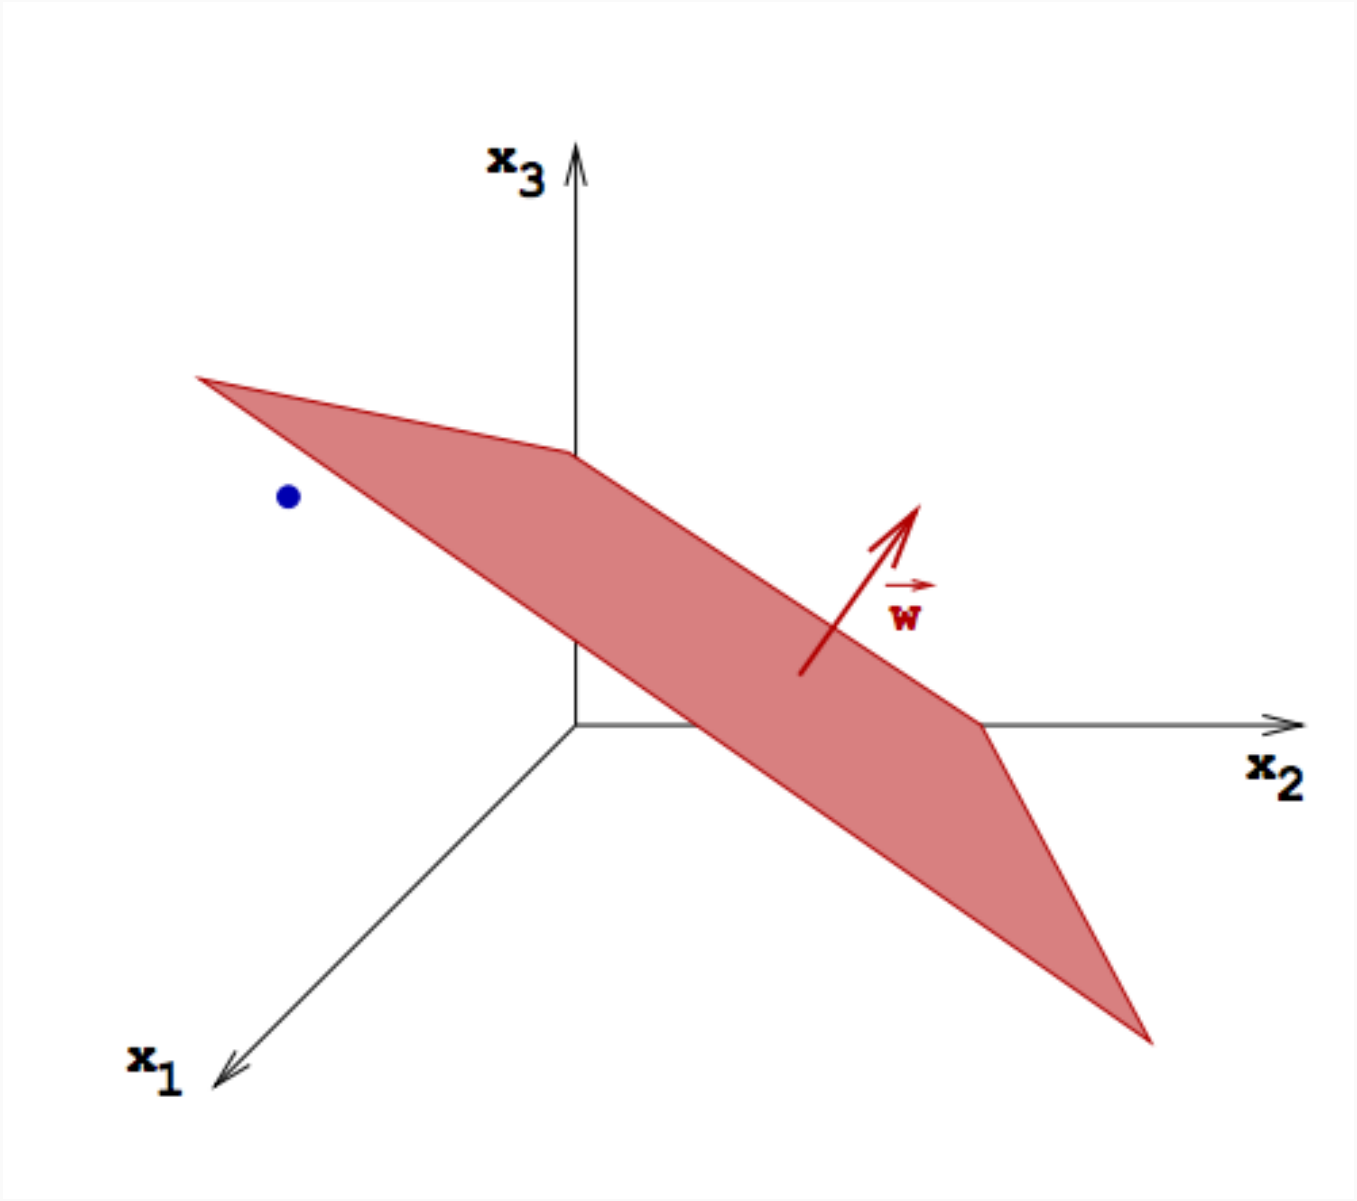
x_3
$\vec{w}$
x_2
x_1

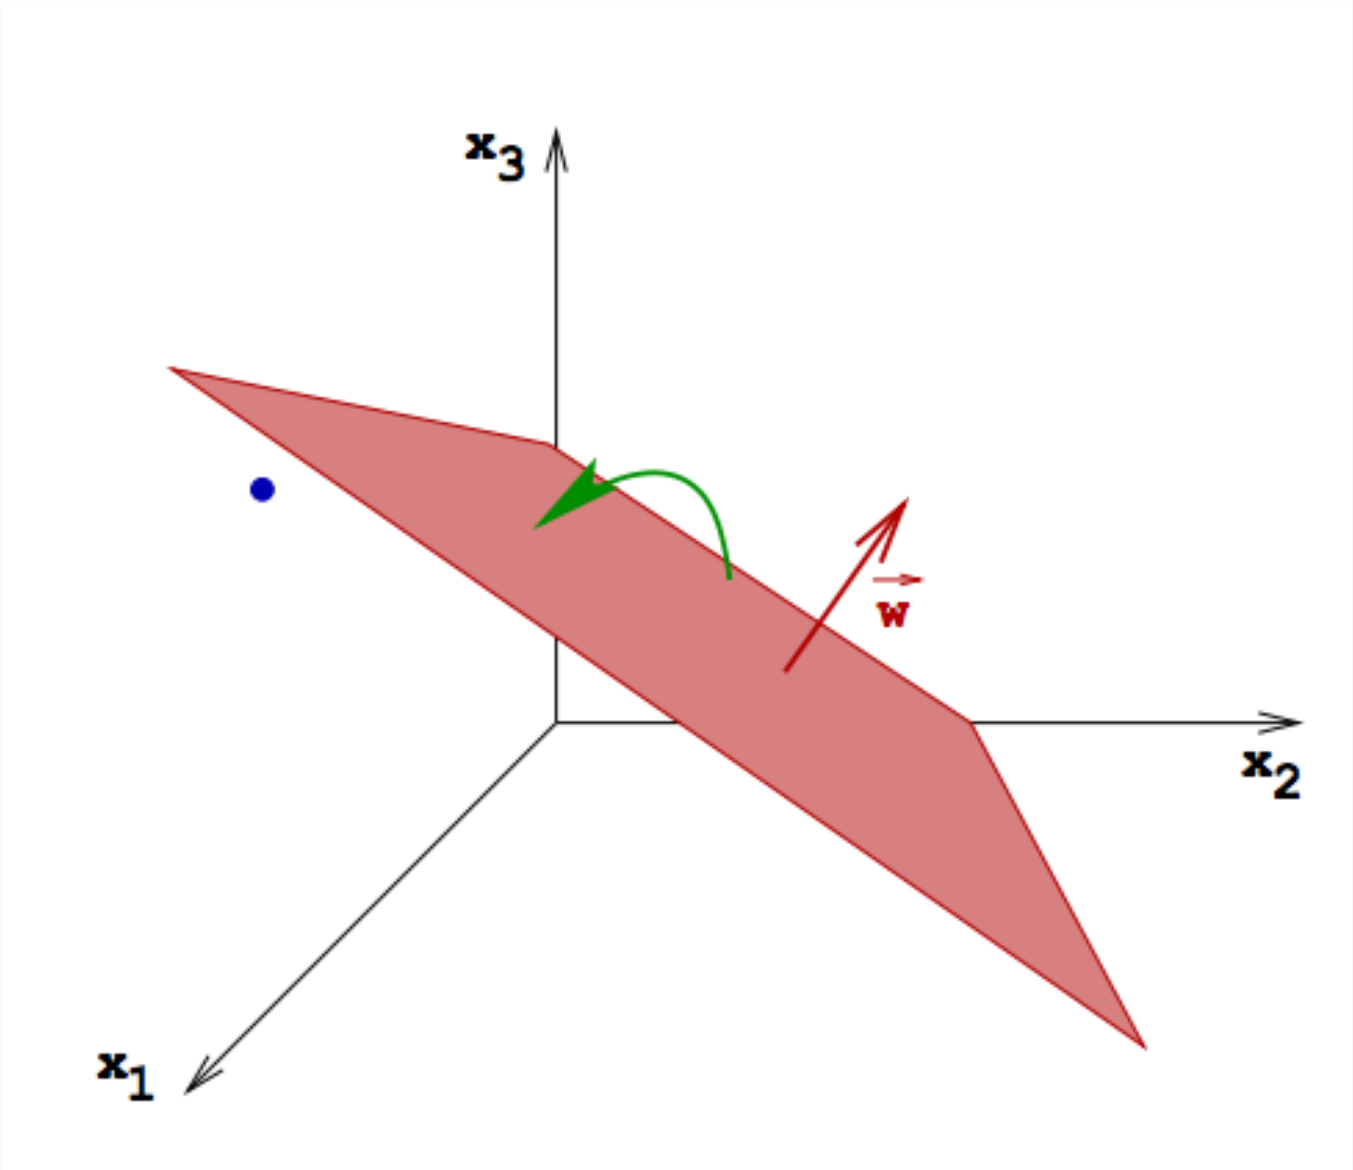
x_3
x_2
x_1
$\vec{w}$

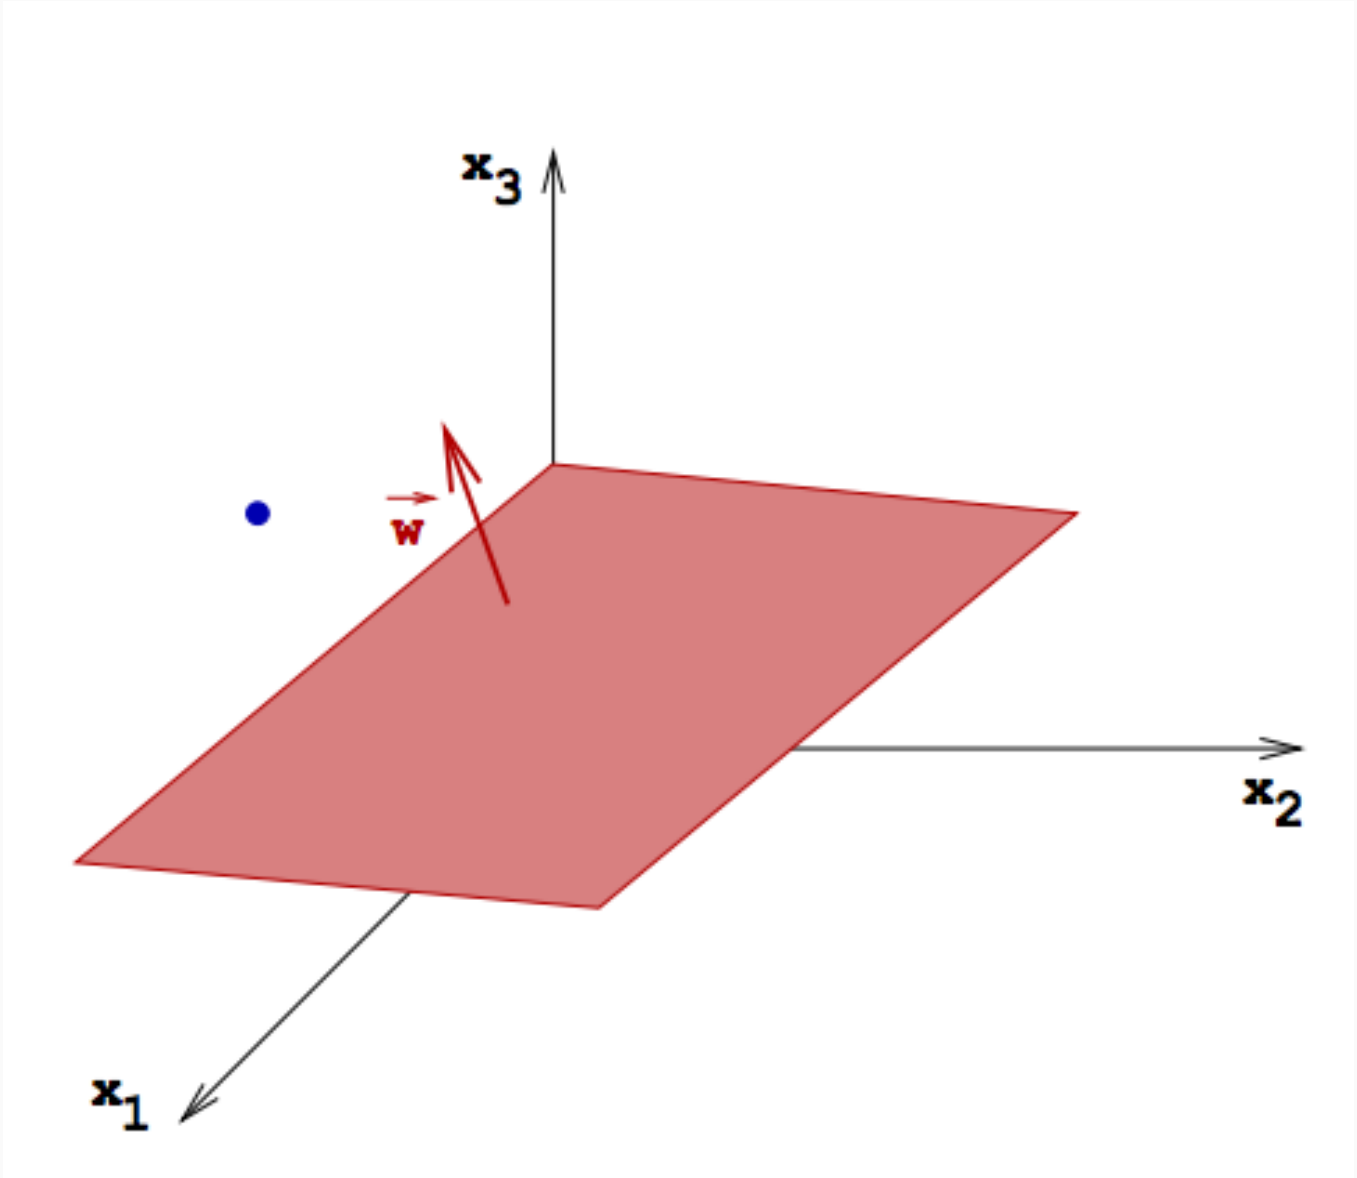
x3
w
x2
x1

Perceptron Learning Algorithm

1 **function** $\mathrm{PLA}(X^l)$
2 Инициализировать $w_0, \ldots, w_n$
3 **repeat**[пока $\mathbf{w}$ изменяются]
4 **for** $i = 1, \ldots, l$ **do**
5 **if** $a(\mathbf{x_i}) \neq y_i$ **then**
6 $\mathbf{w} = \mathbf{w} + y_i \mathbf{x_i}$

Что делать в случае нескольких классов?

Несколько классов

Идея: Для каждого класса заведём отдельный вектор $\mathbf{w_y}$.

Несколько классов

Идея: Для каждого класса заведём отдельный вектор $\mathbf{w_y}$.

$$a(x) = \arg\max_y \langle \mathbf{w_y}, \mathbf{x} \rangle$$

Пример

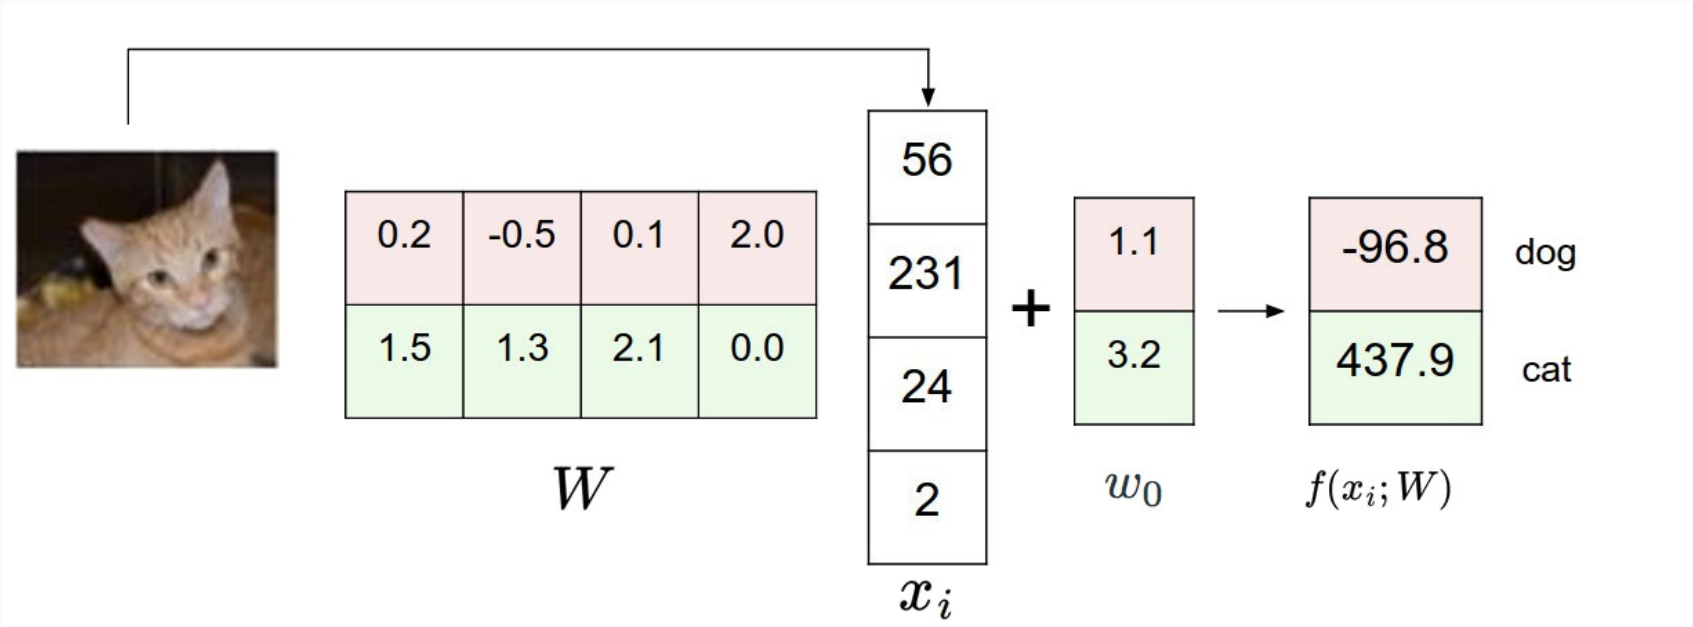
0.2
-0.5
0.1
2.0
1.5
1.3
2.1
0.0
W
56
231
24
2
x_i
+
1.1
3.2
w_0
-96.8
437.9
$f(x_i; W)$
dog
cat

Multiclass PLA

1 **function** $\text{MULTICLASS\_PLA}(X^l)$
2 Инициализировать $\mathbf{w_0}, \ldots, \mathbf{w_n}$
3 **repeat**[пока $\mathbf{w}$ изменяются]
4 **for** $i = 1, \ldots, l$ **do**
5 $a(\mathbf{x_i}) = \arg\max_y \langle \mathbf{w_y}, \mathbf{x_i} \rangle$
6 **if** $a(\mathbf{x_i}) \neq y_i$ **then**
7 $\mathbf{w_y} = \mathbf{w_y} - \mathbf{x_i}$
8 $\mathbf{w_{y^*}} = \mathbf{w_{y^*}} + \mathbf{x_i}$

Будем улучшать алгоритм

Алгоритм

1 **function** MULTICLASS_PLA(X^l, α)
2 Инициализировать $\mathbf{w_0}, \ldots, \mathbf{w_n}$
3 **repeat**[пока $\mathbf{w}$ изменяются]
4 **for** $i = 1, \ldots, l$ **do**
5 $a(\mathbf{x_i}) = \arg\max_y \langle \mathbf{w_y}, \mathbf{x_i} \rangle$
6 **if** $a(\mathbf{x_i}) \neq y_i$ **then**
7 $\mathbf{w_y} = \mathbf{w_y} - \alpha \mathbf{x_i}$
8 $\mathbf{w_{y^*}} = \mathbf{w_{y^*}} + \alpha \mathbf{x_i}$

Наблюдения

+ Алгоритм гарантированно сходится, если обучающая выборка линейно разделима

Наблюдения

+ Алгоритм гарантированно сходится, если обучающая выборка линейно разделима

– Не работает в случае неразделимой выборки

Наблюдения

+ Алгоритм гарантированно сходится, если обучающая выборка линейно разделима

– Не работает в случае неразделимой выборки
– "Слишком правильные" предсказания добавляют штраф

Что делать, если данные не линейно разделимы?

Идея: На этапе предобработки скомбинировать признаки в полиномиальные признаки.

Обобщённый линейный классификатор

Постановка задачи

$X = \mathbb{R}^n$, $Y = \{-1, +1\}$
$X^l = (x_i, y_i)_{i=1}^l$ – обучающая выборка

Задача:
$(n-1)$-мерную гиперплоскость, которая разделяет данные как можно лучше.

Постановка задачи

$X = \mathbb{R}^n$, $Y = \{-1, +1\}$
$X^l = (x_i, y_i)_{i=1}^l$ – обучающая выборка

Задача:
$(n-1)$-мерную гиперплоскость, которая разделяет данные как можно лучше.

Как можно лучше – это как?

Пример

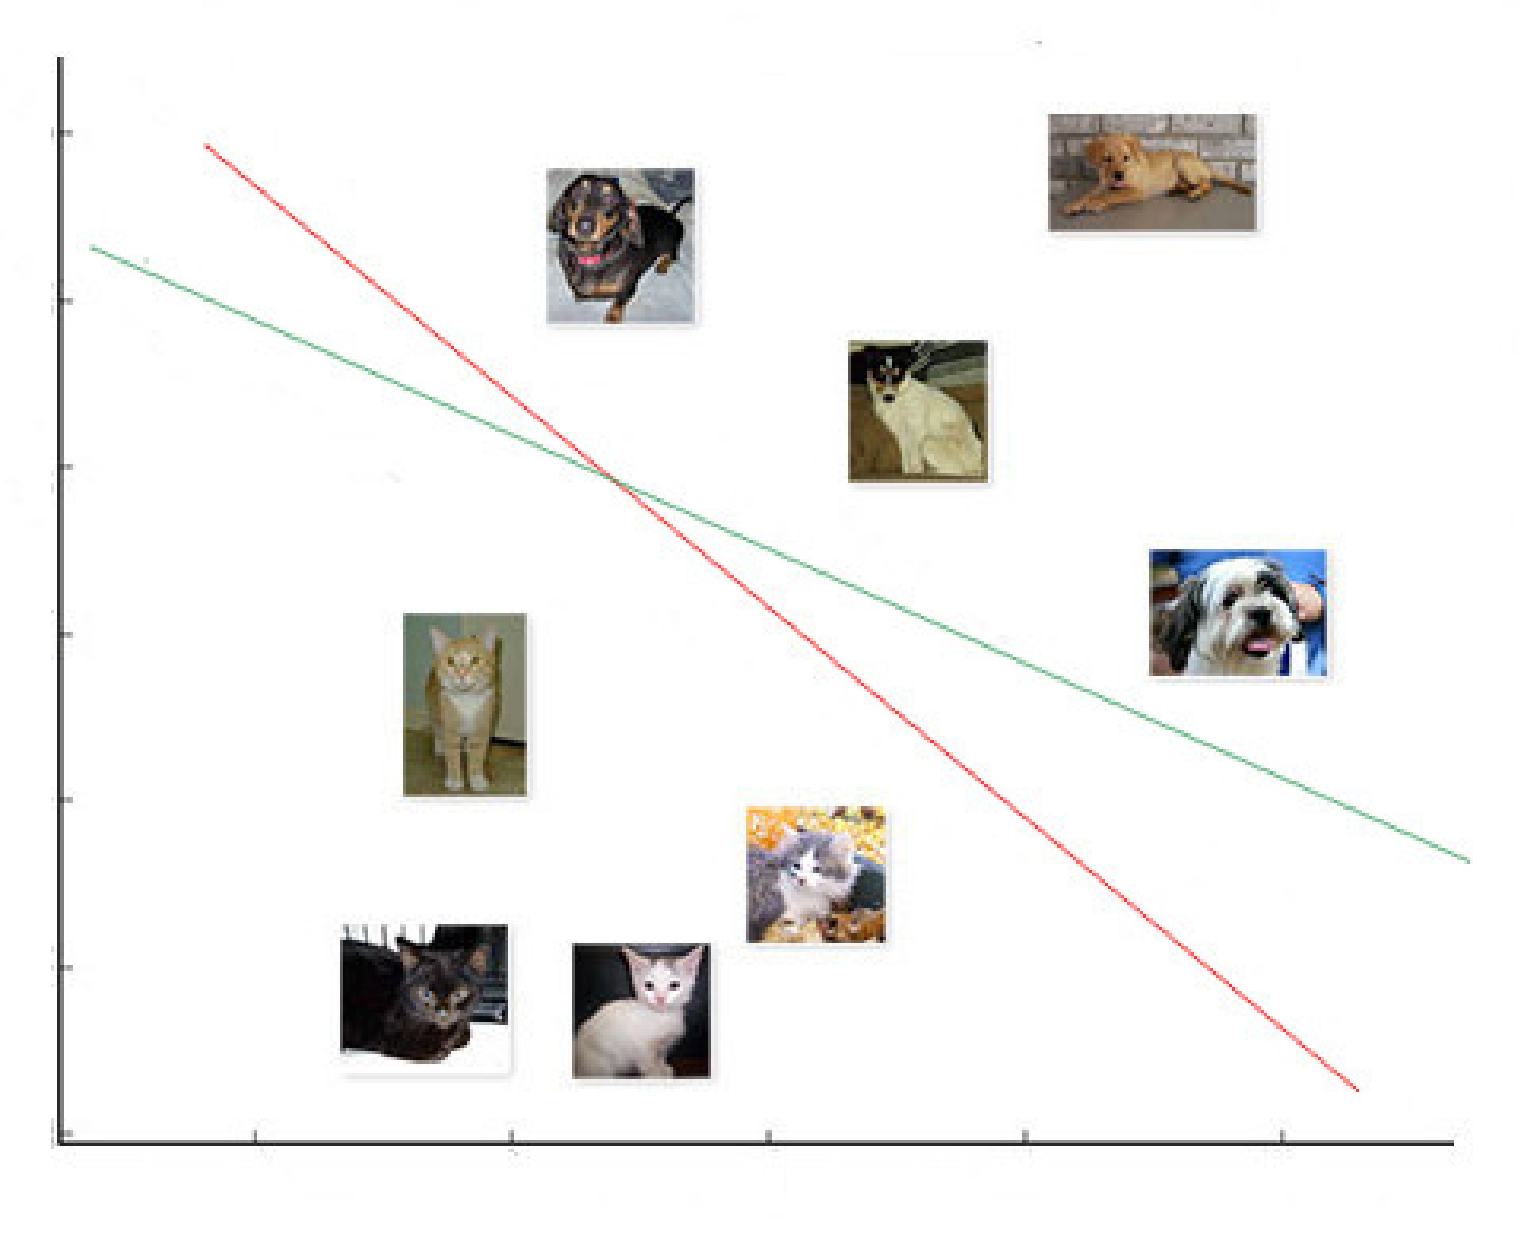

Определение отступа

$g = \langle \mathbf{w}, \mathbf{x} \rangle = 0$ – разделяющая поверхность

$M_i(\mathbf{w}) = \langle \mathbf{w}, \mathbf{x_i} \rangle y_i$ – отступ объекта x_i

$M_i(\mathbf{w}) < 0 \Rightarrow$ алгоритм $a(\mathbf{x}, \mathbf{w})$ ошибается на x_i

Минимизация эмпирического риска

Число ошибок на обучающей выборке:

$$Q(\mathbf{w}) = \sum_{i=1}^{l} [M_i(\mathbf{w}) < 0] \to \min_{\mathbf{w}}$$

Минимизация эмпирического риска

Число ошибок на обучающей выборке:

$$Q(\mathbf{w}) = \sum_{i=1}^{l} [M_i(\mathbf{w}) < 0] \to \min_{\mathbf{w}}$$

– Индикаторную функцию сложно оптимизировать

Минимизация эмпирического риска

Число ошибок на обучающей выборке:

$$Q(\mathbf{w}) = \sum_{i=1}^{l} [M_i(\mathbf{w}) < 0] \to \min_{\mathbf{w}}$$

- Индикаторную функцию сложно оптимизировать
- Теряем информацию насколько i-й объект был надежен

Отступ

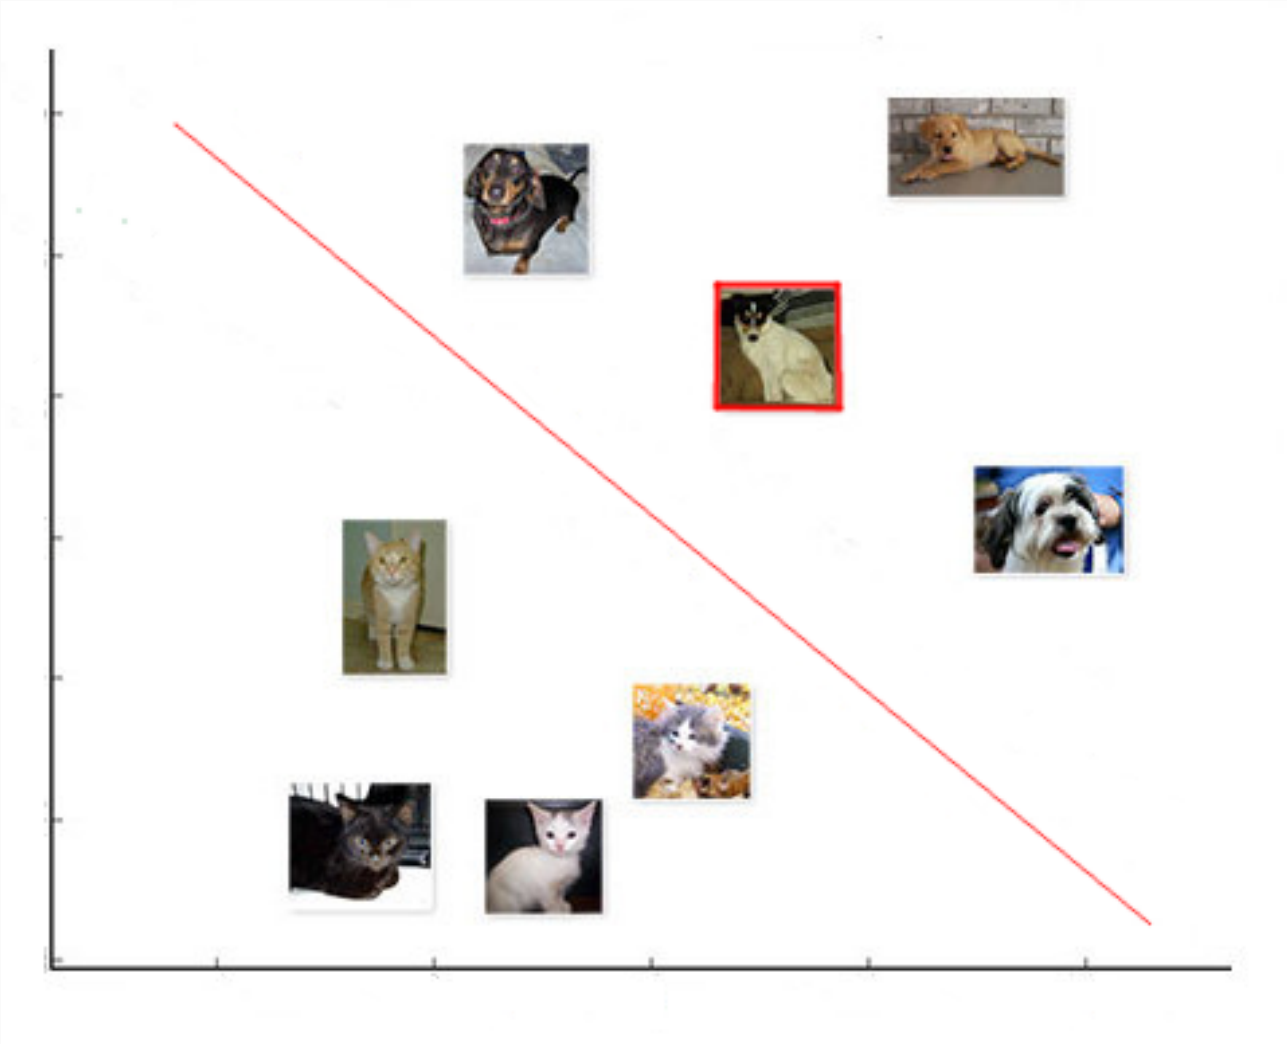

Отступ

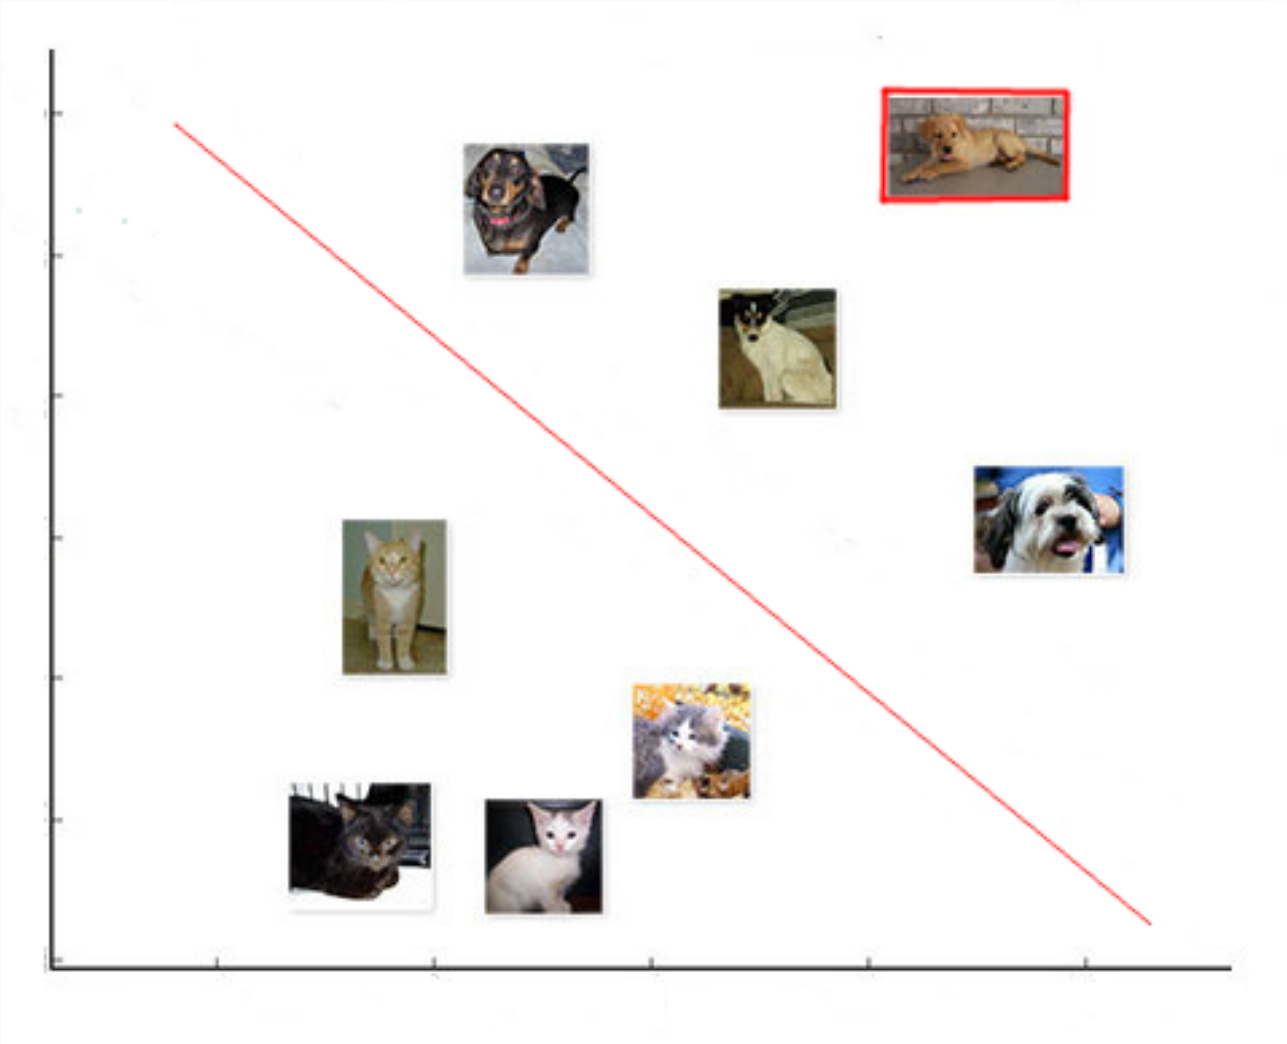

Функция $[M < 0]$

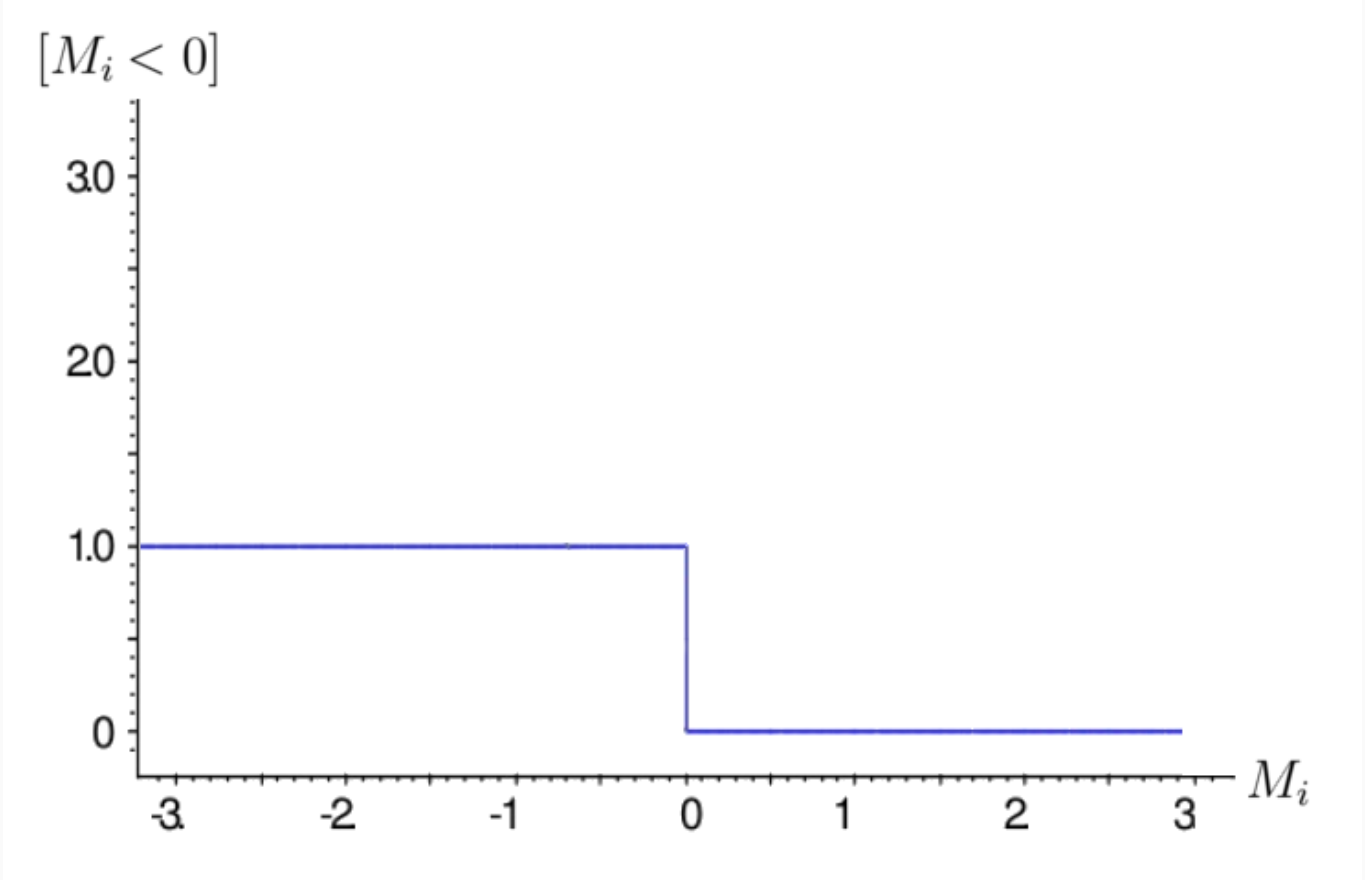

Минимизация эмпирического риска

$$Q(\mathbf{w}) = \sum_{i=1}^{l} [M_i(\mathbf{w}) < 0] \leq \sum_{i=1}^{l} \mathcal{L}(M_i(\mathbf{w})) \to \min_{\mathbf{w}}$$

$\mathcal{L}$ – функция потерь, невозрастающая, неотрицательная.

$\mathcal{L}$ должна мажорировать $[M_i(\mathbf{w}) < 0]$

Примеры $\mathcal{L}$

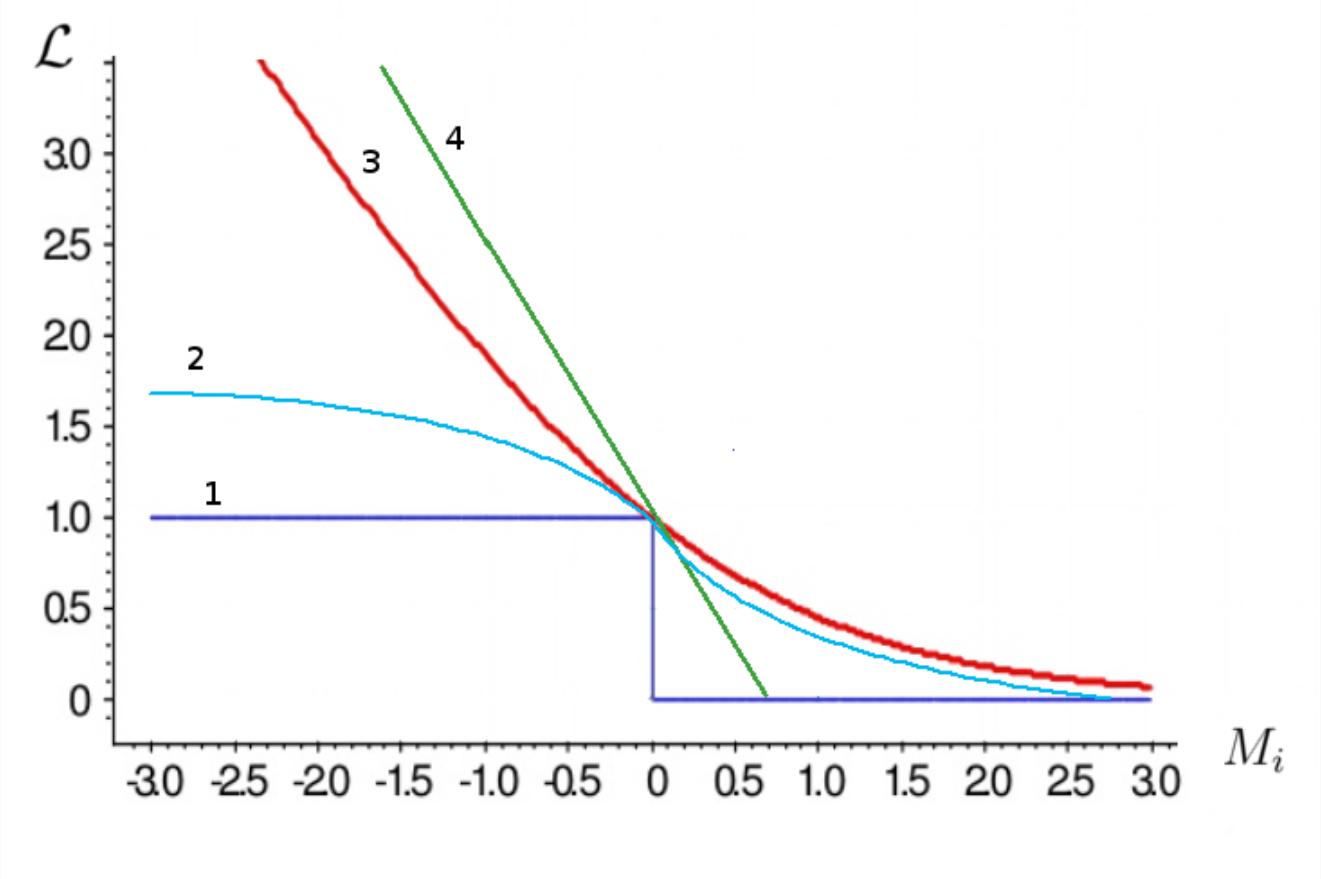

1. $[M_i(\mathbf{w}) < 0]$
2. $S(M) = 2(1 + e^M)^{-1}$ – сигмоидная
3. $L(M) = \log_2(1 + e^{-M})$ – логарифмическая
4. $V(M) = (1 - M)_+$ – кусочно-линейная

Что такое градиент?

Градиент

Метод градиентного спуска

1 **function** GRADIENT_DESCENT(X^l, α)
2 Инициализировать $\mathbf{w}$
3 **repeat**[пока $\mathbf{w}$ изменяются]
4 $\mathbf{w} = \mathbf{w} - \alpha \bigtriangledown Q(\mathbf{w})$

$$\bigtriangledown Q(\mathbf{w}) = \left(\frac{\partial Q(\mathbf{w})}{\partial w_j}\right)_{j=0}^{n} = \sum_{i=1}^{l} \mathcal{L}'(\langle \mathbf{w}, \mathbf{x_i} \rangle y_i) \mathbf{x_i} y_i$$

α – градиентный шаг (темп обучения)

Градиентный спуск

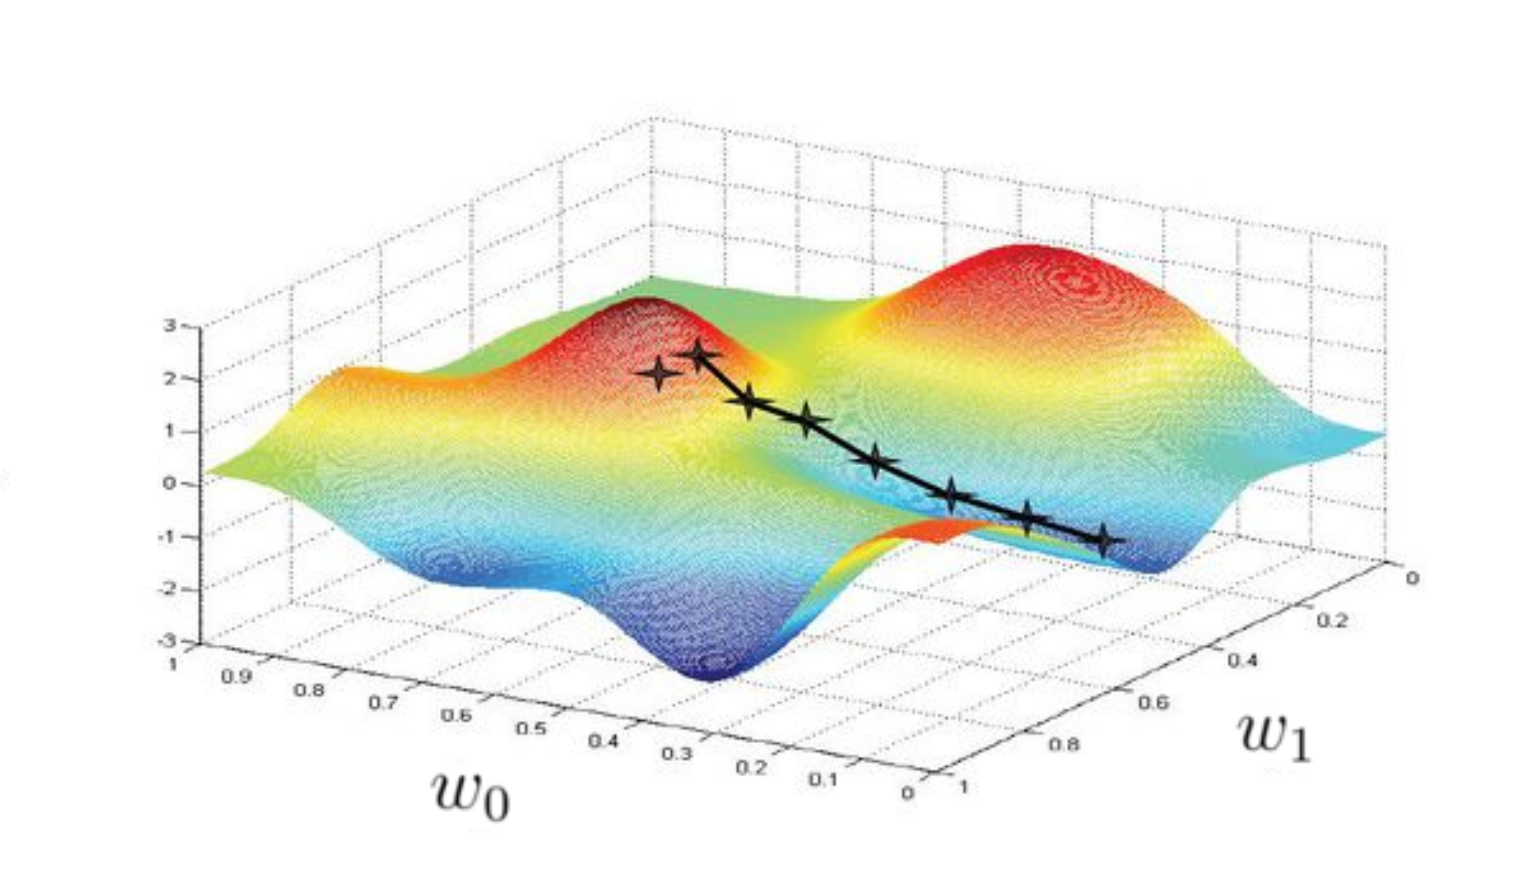

Метод градиентного спуска

Случай двух признаков.

1 **function** $\text{GRADIENT\_DESCENT}(X^l, \alpha)$
2 Инициализировать w_0, w_1
3 **repeat**[пока w_0 и w_1 не стабилизируются]
4 $tmp_0 = w_0 - \alpha \frac{\partial Q(w)}{\partial w_0}$
5 $tmp_1 = w_1 - \alpha \frac{\partial Q(w)}{\partial w_1}$
6 $w_0 = tmp_0$
7 $w_1 = tmp_1$

Почему важно обновить w_0 и w_1 одновременно?

Маленький градиентный шаг

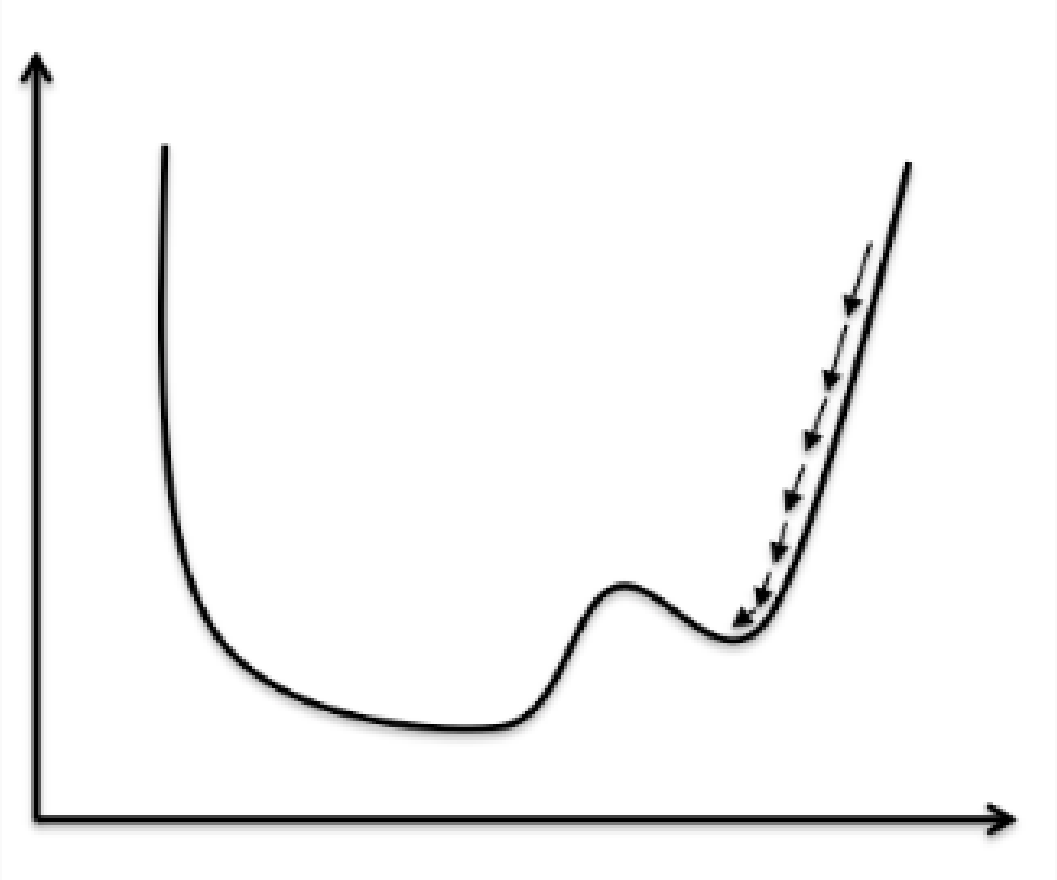

Большой градиентный шаг

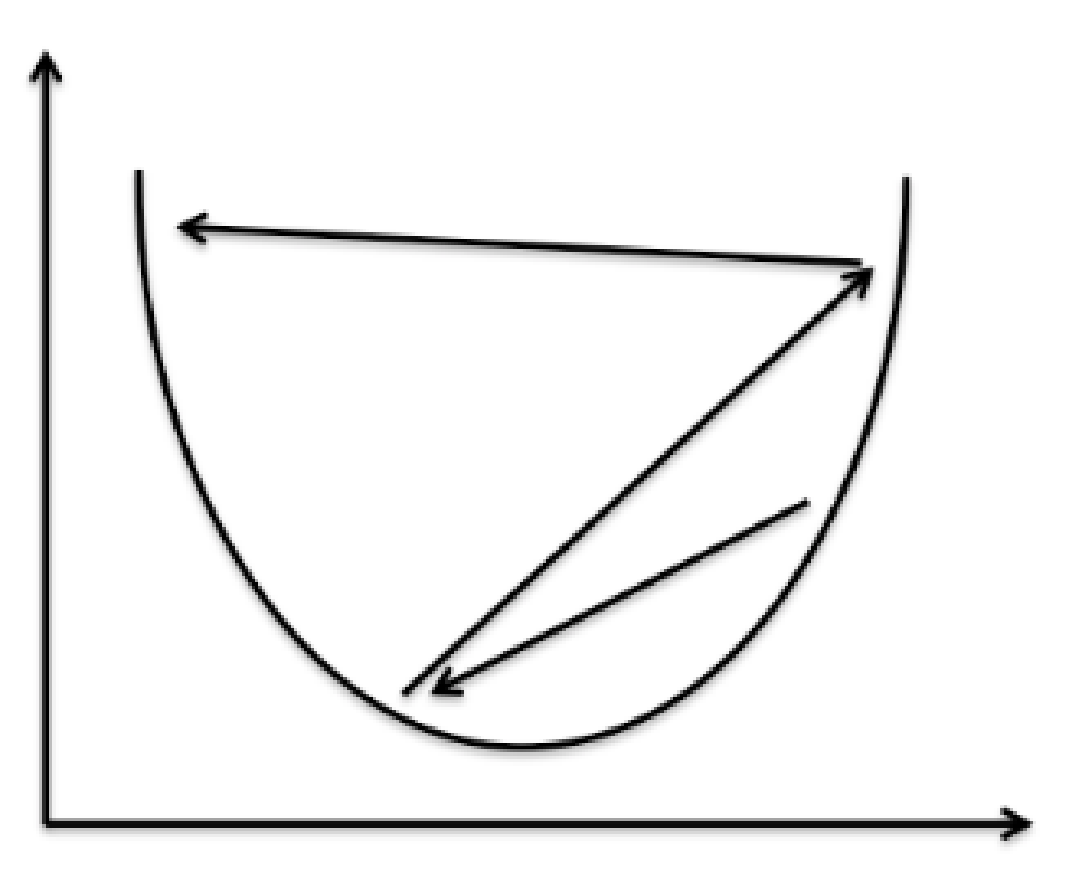

Выбор величины шага

- $\alpha_t \to 0$
- Метод скорейшего градиентного спуска:
  $Q(w - \alpha \bigtriangledown Q(w)) \to \min\limits_{\alpha}$
- Пробные случайные шаги

В чем проблема?

Метод стохастического градиента

$$\mathbf{w} = \mathbf{w} - \alpha \sum_{i=1}^{l} \mathcal{L}'(\langle \mathbf{w}, \mathbf{x_i} \rangle y_i) \mathbf{x_i} y_i$$

Метод стохастического градиента

$$\mathbf{w} = \mathbf{w} - \alpha \sum_{i=1}^{l} \mathcal{L}'(\langle \mathbf{w}, \mathbf{x_i} \rangle y_i) \mathbf{x_i} y_i$$

Идея: Давайте брать (x_i, y_i) по одному и сразу обновлять вектор весов

Алгоритм

1 **function** STOCHASTIC_GRADIENT(X^l, α, η)
2 Перемешать данные в X^l
3 Инициализировать $\mathbf{w}$
4 $Q(\mathbf{w}) = \sum_{i=1}^{l} \mathcal{L}(\langle \mathbf{w}, \mathbf{x_i} \rangle y_i)$
5 **repeat**[пока Q и/или w не стабилизируются]
6 Взять $\mathbf{x_i}$ из X^l
7 Потеря: $\varepsilon_i = \mathcal{L}(\langle \mathbf{w}, \mathbf{x_i} \rangle y_i)$
8 Градиентный шаг: $\mathbf{w} = \mathbf{w} - \alpha \mathcal{L}'(\langle \mathbf{w}, \mathbf{x_i} \rangle y_i) \mathbf{x_i} y_i$
9 Оценить $Q = (1 - \eta)Q + \eta \varepsilon_i$

Градиентный спуск

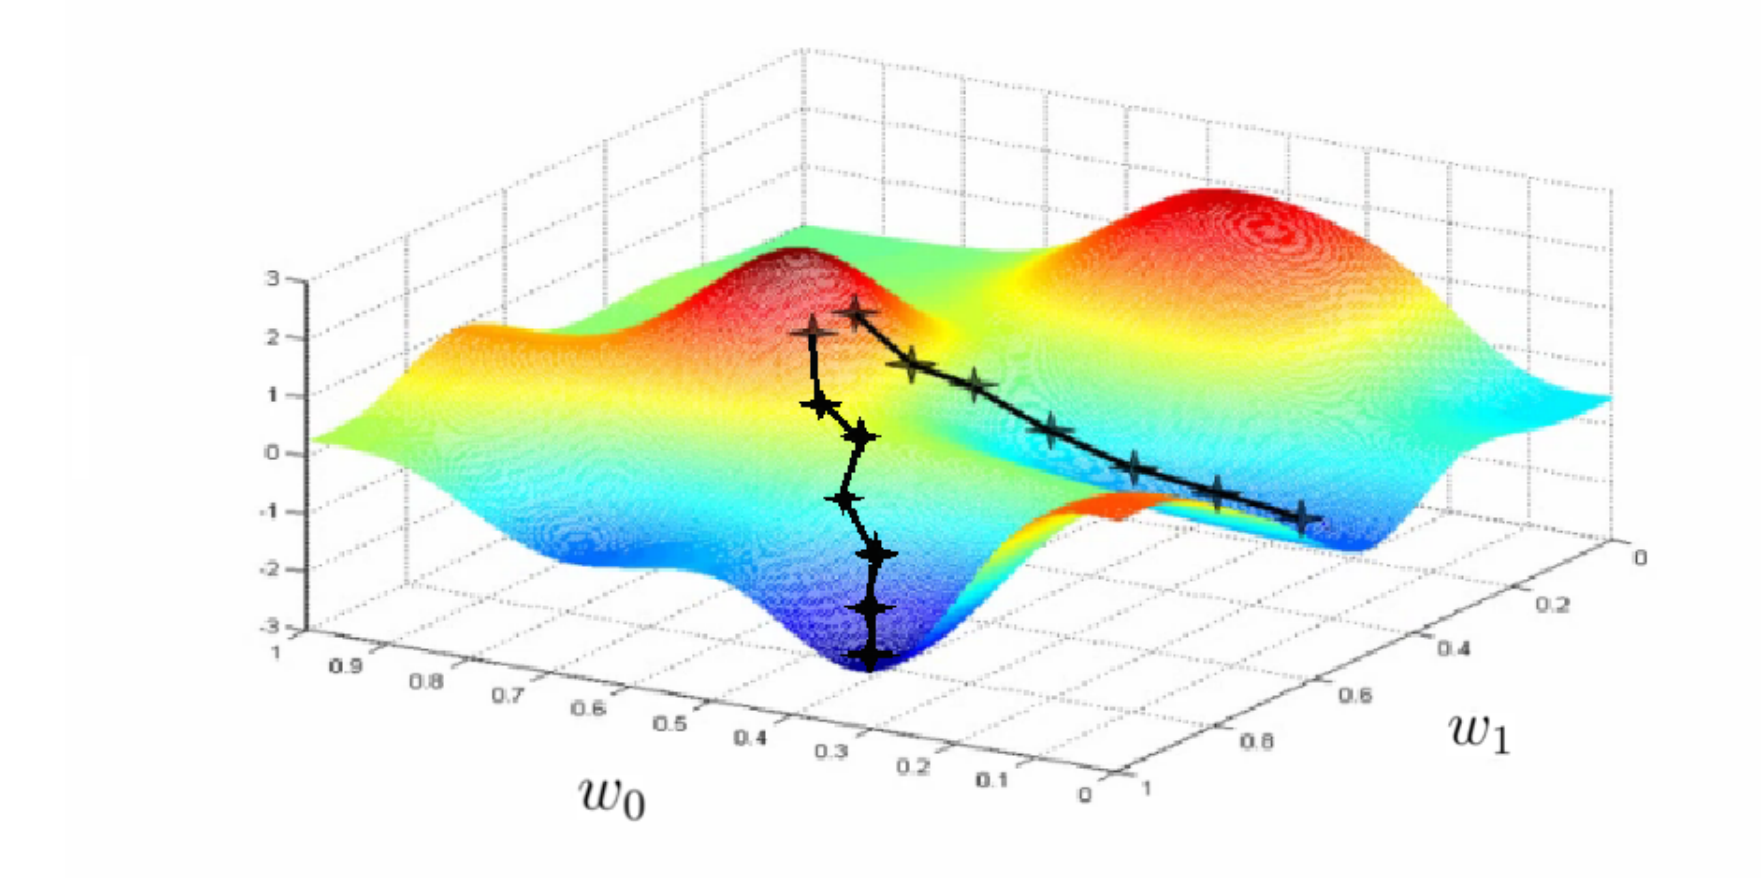

Учет ошибки ε_i в алгоритме

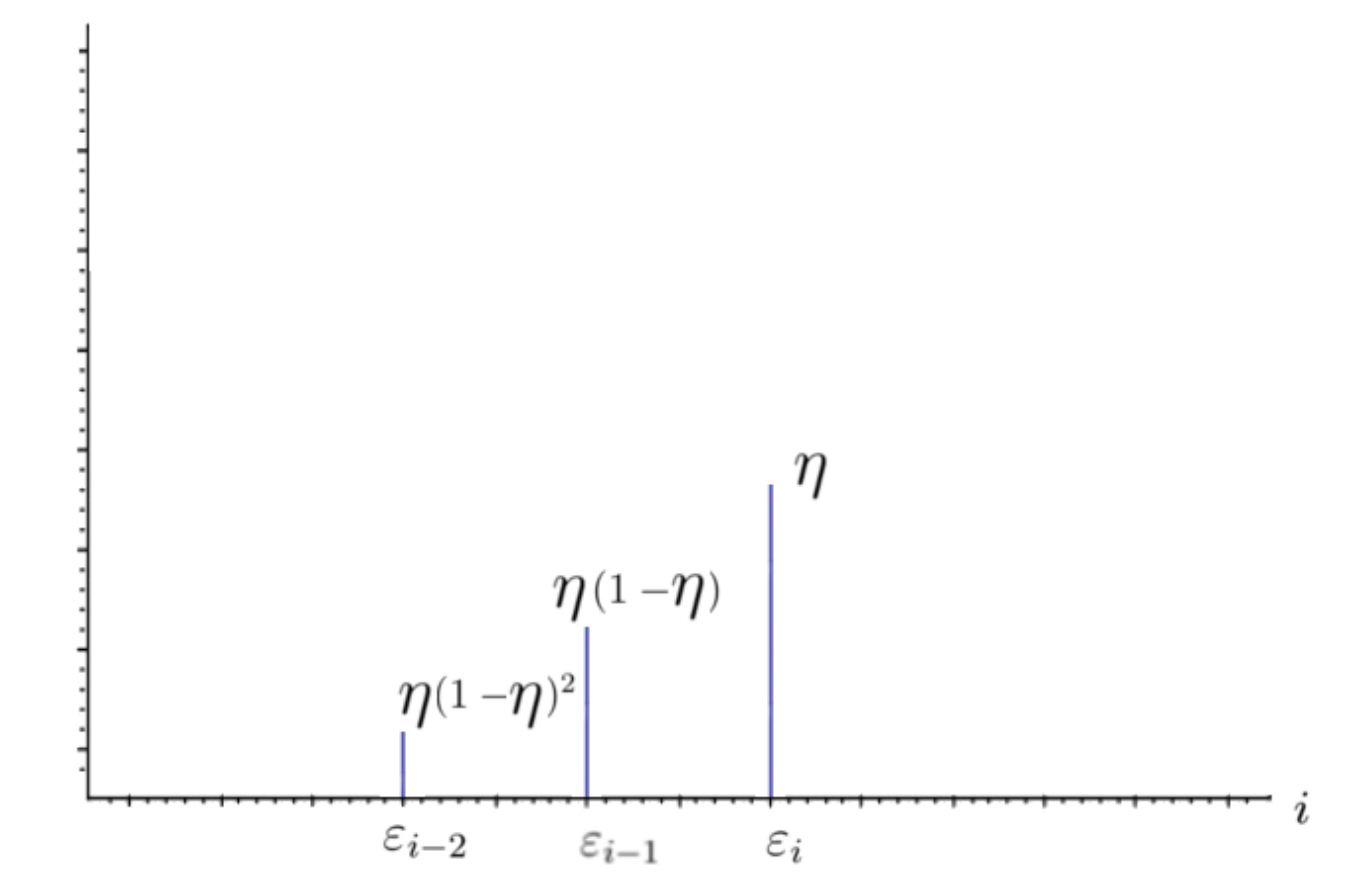

Что значит – "пока Q и/или w не стабилизируются"?

Зависимость Q от номера итерации

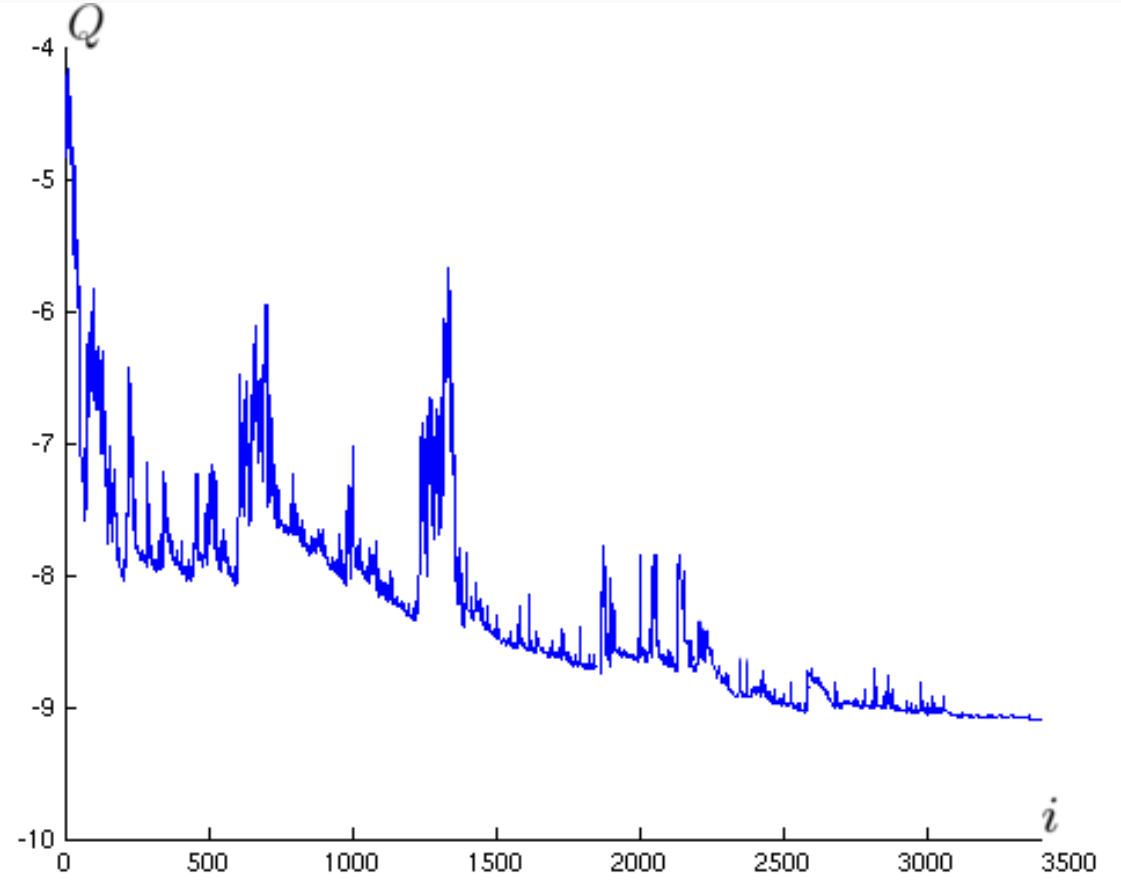

Зависимость Q от номера итерации

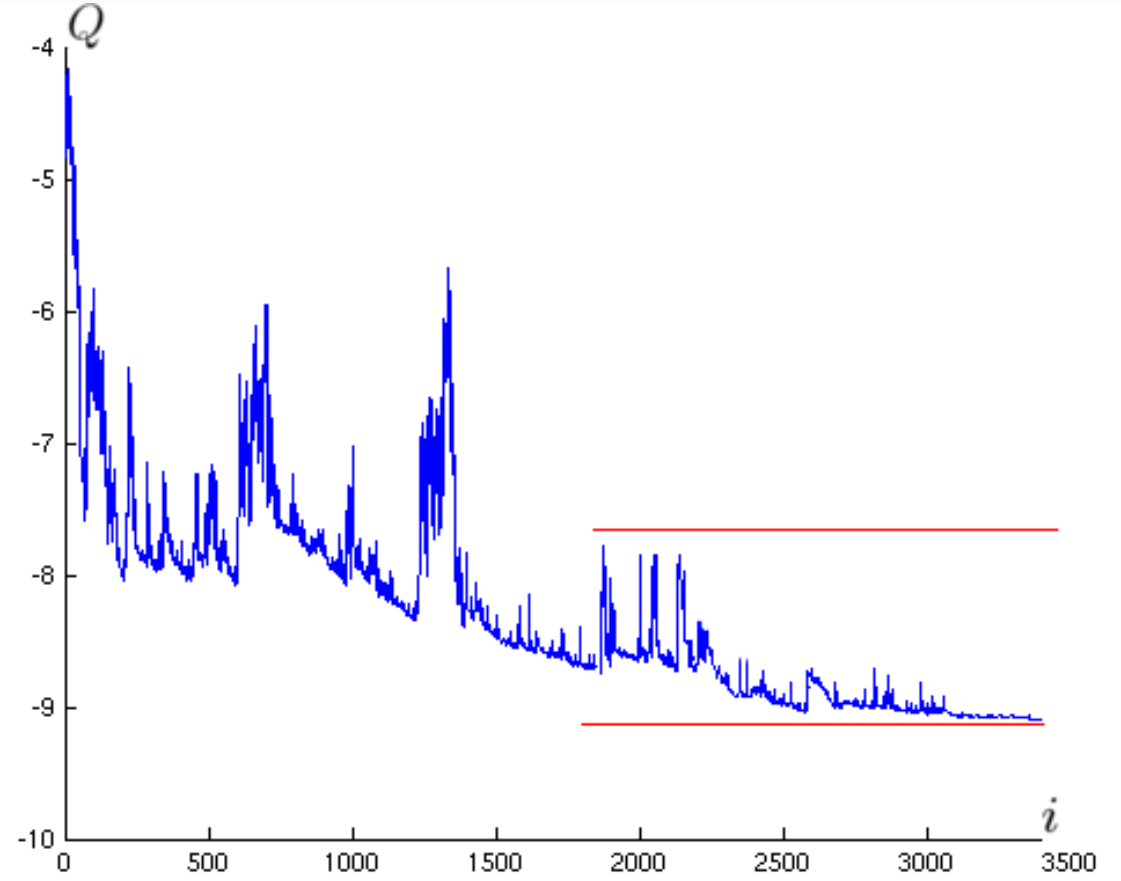

Актуальные вопросы

– Инициализация весов

Актуальные вопросы

- Инициализация весов
- Порядок предъявления объектов

Инициализация весов

Инициализация весов

- $w_j = 0$, j = 1, . . . , n
- $w_j = random(-\frac{1}{2n}, \frac{1}{2n})$ – небольшие случайные значения
- Обучение по небольшой случайной подвыборке объектов
- Многократный запуск из разных случайных начальных приближений

Порядок предъявления объектов

Порядок предъявления объектов

- Попеременно брать объекты из разных классов
- Чаще брать те объекты, на которых была допущена большая ошибка
- Вообще не брать "хорошие" объекты с $M_i > \mu_+$
- Вообще не брать выбросы с $M_i < \mu_-$

Плюсы и минусы

+ Легко реализовать

Плюсы и минусы

+ Легко реализовать
+ Легко обобщить на разные g, $\mathcal{L}$

Плюсы и минусы

+ Легко реализовать
+ Легко обобщить на разные g, $\mathcal{L}$
+ Не обязательно брать все элементы выборки для обучения

Плюсы и минусы

+ Легко реализовать
+ Легко обобщить на разные g, $\mathcal{L}$
+ Не обязательно брать все элементы выборки для обучения

– Возможна медленная сходимость

Плюсы и минусы

+ Легко реализовать
+ Легко обобщить на разные g, $\mathcal{L}$
+ Не обязательно брать все элементы выборки для обучения

– Возможна медленная сходимость
– Застревание в локальных минимумах

Плюсы и минусы

+ Легко реализовать
+ Легко обобщить на разные g, $\mathcal{L}$
+ Не обязательно брать все элементы выборки для обучения

– Возможна медленная сходимость
– Застревание в локальных минимумах
– Подбор параметров

Плюсы и минусы

+ Легко реализовать
+ Легко обобщить на разные g, $\mathcal{L}$
+ Не обязательно брать все элементы выборки для обучения

– Возможна медленная сходимость
– Застревание в локальных минимумах
– Подбор параметров
– Проблема переобучения

Вопросы?

Что почитать по этой лекции

- Professor Yaser Abu-Mostafa MOOC
- Tom Mitchell "Machine Learning" Chapter 4

На следующей лекции

- Функционалы качества
- Неравенство Хефдинга
- Близость гипотез
- Неравенство Вапника-Червоненкиса
- Генерация модельных данных